
Chapter 2 | PE 与脉动阵列

- 本章目标：实现 NPU 的计算核心。
- 内容：PE、weight-stationary 数据流、斜输入、输出对齐。
- 验收：make sim-06 全 PASS。

Chapter 2 | 从乘累加开始

- MAC 是 CNN 的最小计算单元： $\text{acc} += a * w$ 。
- int8 乘法 + int32 累加，精度与面积平衡。
- PE 是 MAC 的硬件化：输入 a 、权重 w 、部分和 psum 。

Chapter 2 | PE 接口

- a_{in} / a_{out} : 激活从左侧流入、向右流出。
- $psum_{in} / psum_{out}$: 部分和从上方流入、向下流出。
- w_{load} / w_{in} : 权重装载。
- 输出 : $psum_{out} = psum_{in} + a_{in} * w$ 。

Chapter 2 | 为什么叫脉动

- 数据像心跳一样在 PE 之间逐拍流动。
- 每个 PE 只和邻居通信，没有全局广播。
- 寄存器流水让每个周期所有 PE 都在工作。

Chapter 2 | Weight-Stationary 数据流

- 权重先批量装载，之后停留在 PE 内。
- 激活逐拍流过阵列，部分和向下累加。
- 权重复用率 = 该权重被使用的次数。
- 卷积场景下权重复用率很高，适合这个方案。

Chapter 2 | 斜输入

- 阵列第 row 行的输入需要延迟 row 拍。
- 这样才能让所有行在同一拍处理同一个 k。
- 外部不需要打 skew：阵列内部自动对齐。

Chapter 2 | 输出对齐

- 列 j 的结果天然比列 $j-1$ 晚一拍。
- 在底部对第 col 列额外延迟 $N-1-col$ 拍。
- 最终所有列在同一拍输出，方便后续控制器取数。

Chapter 2 | 时序示例

- w_load 高电平装载权重。
- 之后每拍送一个 a_data 向量。
- 最后一个输入送入后再等 $N-1$ 拍，开始逐拍输出。
- 示例： $N=8$ ，送入 8 个向量，输出 8 个结果向量。

Chapter 2 | 参数化设计

- N：阵列大小，8x8 起步，可扩展到 16x16。
- A_W / W_W：激活和权重位宽，默认 8。
- P_W：累加位宽，默认 32。
- 参数化让同一个 RTL 可以用于不同算力配置。

Chapter 2 | 本章任务

- 补全 PE：权重寄存器 + 有符号乘累加。
- 补全阵列：斜输入、PE 互联、输出对齐。
- 跑通 PE_tb 与 SystolicArray_tb。

Chapter 2 | 常见错误

- 忘记 signed, 导致负数乘法错误。
- w_data 位宽写成 $N \times W_W$, 应该是 $N \times N \times W_W$ 。
- 采样时机不对, 把斜输出当成错误。
- 复位不完整, 初值 x 传播到输出。

Chapter 2 | 总结

- PE 是最小的 MAC 单元。
- 脉动阵列通过数据复用把 MAC 密度拉满。
- 斜输入 + 输出对齐是正确时序的关键。
- 下一章：给阵列加上 SRAM 和控制器，做真正的卷积。