

From Nand to Tetris

NPU Extension

Chapter 4: 模型训练与量化导出

Model Training, Quantization and Export

Assignment

Building a Modern Computer From First Principles

Introduction

本章作业以脚本和报告为主，最终要有一份“float vs int8”的精度对比。

Questions

Q1. 给出你的 tiny CNN 结构，说明为什么选择这些通道数和层数。

Hint: 考虑 8x8 阵列的 tiling 和 MNIST 输入大小。

Q2. 取一个卷积层的权重张量，手工计算 per-tensor scale，并量化 5 个示例值。

Hint: $\text{scale} = \max(\text{abs}(w)) / 127$ （对称量化）。

Q3. 解释为什么推理时可以把 BN 折叠进卷积，并写出折叠公式。

Hint: 推理时 mean/var 是常量。

Q4. Python int8 模拟的准确率比 float 低多少？如果低于 95%，你会怎么调整？

Hint: 调 scale、校准集、模型容量。

Q5. 设计一个端到端检查：如何证明 RTL 的最终 logits 与 Python golden 一致？

Hint: argmax 一致 + 数值误差上界。

What to Submit

- tools/npu_mnist.py 源码。
- npu_data/ 生成文件。
- 量化精度报告（float vs int8）。
- Q1-Q5 书面回答。

Rubric

Item	Points
训练脚本可复现	20
量化实现正确	25
导出格式与 RTL 布局一致	25
精度报告完整	15
书面推导正确	15

Total: 100 points