

From Nand to Tetris

NPU Extension

# Chapter 5: 整机集成与端到端推理

SoC Integration and End-to-End Inference

Assignment

Building a Modern Computer From First Principles

# Introduction

本章是收官作业：系统集成 + 驱动 + 端到端验证。

## Questions

Q1. 写出 Hack 驱动的伪代码：加载地址、启动 NPU、轮询完成、读取结果。

Hint: 用伪代码或 Hack 汇编均可。

Q2. 设计命令描述符：如果一次推理包含多层，CPU 如何把“每层的地址和参数”告诉 NPU？

Hint: 可以定义内存中的描述符表，CPU 只写表头地址。

Q3. 从 START 到 DONE 统计实际周期，并与 Ch2/Ch3 的理论周期对比，分析差距来源。

Hint: 权重加载、tiling、流水排空、轮询开销都算。

Q4. 如果端到端结果与 golden 不一致，给出你的排查顺序。

Hint: MMIO -> 状态机 -> 单层输出 -> 量化参数。

Q5. 评估把本章系统扩展到 tiny YOLO 需要改哪些部分，哪些可以复用。

Hint: conv/FC 复用；需要 upsample、concat、检测头、NMS。

## What to Submit

- 改造后的 Memory.v / Computer.v。
- npu\_driver.asm 与 .hack。
- 集成 testbench 的 PASS 输出。
- 性能与利用率报告。
- Q1-Q5 书面回答。

## Rubric

| Item           | Points |
|----------------|--------|
| MMIO 集成正确且向后兼容 | 25     |
| Hack 驱动正确      | 20     |
| 端到端推理 PASS     | 30     |
| 性能报告           | 10     |
| 书面回答           | 15     |

Total: 100 points