

From Nand to Tetris

NPU Extension

Chapter 5: 整机集成与端到端推理

SoC Integration and End-to-End Inference

Project

Building a Modern Computer From First Principles

Background

现在 NPU 有算力、有控制器、有权重。最后一步是把 NPU 作为外设挂进现有 Hack Computer，用 Hack 机器码发起一次 MNIST 推理，并把结果写回内存。

这一章把 nand2tetris 的整机（Project 5）和前面的 NPU 工程串成一条完整链路：CPU 调度 -> NPU 计算 -> 结果回读。

Objective

扩展 `n2t\_memory\_posedge` / `n2t\_computer\_posedge`：在 0x7000-0x7FFF 增加 NPU MMIO。

编写一条 Hack 汇编驱动：写命令、轮询状态、读取结果。

集成测试：加载一张 MNIST 图片，端到端输出正确类别。

保持原有 `make test`（Project 1/2/3/5/6）全部通过。

Deliverables

- 改造后的 Memory.v / Computer.v（向后兼容）。
- Hack 驱动 `npu\_driver.asm` + 编译后的 `npu\_driver.hack`。
- 端到端集成 testbench 与 PASS 输出。

Contract

- 原有官方测试必须继续全绿（不破坏 nand2tetris 语义）。
- MMIO 地址不与 RAM/Screen/Keyboard 冲突。
- 驱动必须通过轮询 STATUS 等待 NPU 完成，不允许 busy-wait 死循环失控。
- 最终结果写入约定内存地址，测试台能够读到并断言正确类别。

Resources

- `solution/05/Computer.v`、`solution/05/Memory.v`、`solution/05/ROM32K.v`。
- `programs/\*.hack`：现有 Hack 程序示例。
- Ch4 导出的 image.hex / weights.hex / scales.json。

Tips

- 先在 Memory 里加一个简单的 MMIO 译码，再接 NPU；不要一步到位。
- Hack 没有乘法，驱动里只做地址计算和轮询，计算全部交给 NPU。
- 用 waveform 观察 CMD 与 STATUS 的时序，确认没有握手竞争。
- 端到端先跑 1 张图，验证 argmax 后再考虑批量。